

Segmentación Semántica de Imágenes de Mascotas

Entrega 1 · Aprendizaje de Máquina Aplicado · EAFIT · Prof. Marco Terán
Autores: Jose Blanco · Miguel Quijano · 26 de abril de 2026

1. Problema planteado

Dado una imagen RGB que contiene una mascota (perro o gato), el objetivo es generar una **máscara binaria** del mismo tamaño espacial que la imagen, donde cada píxel se clasifica como **1 (mascota)** o **0 (fondo)**. Se trata de un problema de **segmentación semántica binaria**: clasificación supervisada a nivel de píxel.

2. Motivación

La segmentación semántica es una de las tareas centrales en visión por computador, con aplicaciones en diagnóstico médico, conducción autónoma y edición de imágenes. La segmentación de mascotas en imágenes naturales sirve como banco de pruebas accesible para explorar las técnicas centrales del campo (arquitecturas encoder-decoder, métricas robustas al desbalance, data augmentation) sin requerir infraestructura desproporcionada para el curso.

3. Breve contexto

El uso de Redes Neuronales Convolucionales (CNNs) está técnicamente justificado: (i) los datos son imágenes con estructura espacial 2D, donde la cercanía entre píxeles es informativa; (ii) la tarea requiere razonar tanto sobre contexto local como global, lo que las arquitecturas encoder-decoder modelan eficientemente; y (iii) los enfoques clásicos (umbralización, k-means sobre color) son demostrablemente insuficientes para este tipo de imágenes naturales.

4. Descripción de datos

Se utilizó el **Oxford-IIIT Pet Dataset** (Visual Geometry Group, Universidad de Oxford), benchmark estándar en visión por computador. Contiene ~7,349 imágenes de mascotas distribuidas en 37 razas (25 de perros, 12 de gatos), con anotaciones pixel-nivel mediante *trimaps* (1 = mascota, 2 = fondo, 3 = borde). Para esta tarea binaria, el trimap se colapsa: $1 \rightarrow 1$ y $\{2, 3\} \rightarrow 0$.

Fuente	Visual Geometry Group, University of Oxford
URL	https://www.robots.ox.ac.uk/~vgg/data/pets/
Tamaño	~7,349 imágenes con trimap
Resolución	Variable (mediana 500 × 375 px)
Tarea	Segmentación semántica binaria
Licencia	CC BY-SA 4.0

Tabla 1. Data card resumido del dataset.

Limitaciones identificadas: resolución variable (requiere redimensionamiento), ambigüedad en la clase *boundary* al colapsar a binario, sesgo cultural hacia mascotas domésticas occidentales, y ausencia de oclusiones severas o múltiples mascotas por imagen.

5. Hallazgos del EDA

El análisis exploratorio revela cuatro hallazgos clave que orientan el modelado:

- (1) **Desbalance moderado a nivel de píxel:** 59.9% fondo, 29.2% mascota, 11.0% bordes (Figura 1, izquierda). Esto descarta Pixel Accuracy como métrica principal y motiva el uso de IoU.
- (2) **Distribución balanceada por raza:** la mayoría de las 37 razas tiene exactamente 100 imágenes en trainval, eliminando el desbalance por raza como problema. Sin embargo, persiste el desbalance perros/gatos (25 vs. 12 razas).
- (3) **Resoluciones heterogéneas:** mediana 500×375 px con aspect ratios concentrados en 0.75, 1.33 y 1.5. Cualquier redimensionamiento uniforme introduce distorsión geométrica.
- (4) **Proporción mascota/imagen variable:** la mascota ocupa entre el 15% y el 50% de la imagen (media 0.30, Figura 1 derecha), lo que asegura que el problema no es trivialmente reducible a localización por tamaño.




Figura 1. Izquierda: distribución global de píxeles del trimap. Derecha: histograma de la proporción de mascota por imagen.




Figura 2. Muestras del dataset. De izquierda a derecha: imagen, trimap, máscara binaria derivada, superposición.

6. Baseline

Métrica principal: IoU (Intersection over Union); **secundaria:** Dice Coefficient. Se descarta Pixel Accuracy por ser engañosa bajo desbalance: un modelo que predice todo como fondo obtendría ~70% de Pixel Accuracy con IoU = 0.

Se construyeron **dos baselines** reproducibles (semilla = 42): **(1) Majority Class** que predice todo como fondo, y **(2) CNN encoder-decoder simple** sin skip connections, entrenada con BCE Loss, Adam ($\text{lr}=1\text{e-}3$), 15 épocas, batch size 32. La elección deliberada de no usar skip connections establece un punto de comparación claro contra arquitecturas más sofisticadas en la Entrega 2.

Modelo	IoU	Dice	Pixel Accuracy
Todo Background	0.001	0.001	0.702
Todo Foreground	0.298	0.439	0.298
CNN Simple (baseline)	0.628	0.759	0.873

Tabla 2. Resultados en validación.




Figura 3. Comparación visual de las tres estrategias.

7. Primeras conclusiones

- (a) El baseline trivial 'todo fondo' confirma empíricamente que **Pixel Accuracy es engañosa**: alcanza 0.702 de accuracy pero IoU = 0.001. Esto valida la elección de IoU como métrica principal.
- (b) La CNN simple alcanza **IoU = 0.628**, superando ampliamente a ambos baselines triviales. El enfoque CNN es válido y el modelo aprende información útil de las imágenes.
- (c) El gap entre el baseline CNN (0.628) y el estado del arte para este dataset (~0.93 con U-Net) confirma que el problema es **aprendible pero no trivial**, dejando margen amplio de mejora para arquitecturas más sofisticadas.
- (d) El análisis cualitativo de predicciones evidencia que las predicciones son **borrosas y pierden detalles finos** (orejas, patas), consecuencia directa de la ausencia de skip connections. Estos errores son exactamente los que U-Net está diseñada para resolver, lo cual fundamenta el plan para la Entrega 2: implementar U-Net y comparar con otra familia de modelos (FCN o transfer learning).