

Segmentación Semántica de Imágenes de Mascotas

Entrega 2 · Comparación de familias de modelos y validación
Aprendizaje de Máquina Aplicado · EAFIT · Prof. Marco Terán
Autores: Jose Blanco · Miguel Quijano · 14 de mayo de 2026

1. ¿Qué modelos se compararon y por qué?

Se compararon **tres familias de modelos** diferenciadas filosóficamente para entender cómo distintas decisiones de diseño afectan el desempeño en segmentación binaria:

- (1) **CNN encoder-decoder simple** — el baseline de Entrega 1, sin skip connections. Sirve como punto de partida para medir mejoras.
- (2) **U-Net from scratch** — encoder-decoder con skip connections para recuperar detalles espaciales finos. Aborda directamente la limitación principal del baseline (predicciones borrosas).
- (3) **U-Net + ResNet18 preentrenado** — usa *transfer learning* con un encoder preentrenado en ImageNet. Evalúa si features generales aprendidas en datos masivos aportan valor al problema específico.

Esta elección permite analizar tres dimensiones: **arquitectura** (con/sin skips), **inicialización** (random vs preentrenada) y **filosofía** (entrenamiento desde cero vs transfer learning).

2. ¿Cómo se evitó el data leakage?

Se aplicaron cuatro mecanismos concretos de control:

- (1) **Split estratificado por raza** usando StratifiedShuffleSplit (80% train / 20% val) sobre trainval, con verificación explícita de no-overlap (`assert len(set(train_idx) & set(val_idx)) == 0`).
- (2) **Estadísticas de normalización calculadas SOLO sobre train** (media y desviación por canal), nunca sobre el dataset completo.
- (3) **Test set intocable** durante todo el entrenamiento y la selección de modelos. Se evalúa una sola vez al final, tras elegir el modelo en validación.
- (4) **Threshold óptimo elegido en validación**, nunca en test. Mismo principio para la selección de la mejor época (early stopping implícito por val IoU).

3. Protocolo experimental

Configuración común para los 3 modelos (comparación justa):

Parámetro	Valor
Resolución	128 × 128 px
Batch size	32
Épocas	15
Optimizador	Adam (lr=1e-3)
Loss	Binary Cross-Entropy (BCE)
Augmentación	Flip horizontal aleatorio
Semilla	42 (todas las operaciones aleatorias)
Selección de modelo	Mejor val IoU sobre las 15 épocas

Splits	Train: 2944, Val: 736, Test: 3669
---------------	-----------------------------------

Tabla 1. Configuración común a los 3 modelos.

4. Resultados comparativos

Modelo	Params	Tiempo	Val IoU	Val Dice	Val PixAcc	Test IoU	Test Dice
SimpleCNN (E1)	0.33M	4.3 min	0.656	0.780	0.886	0.654	0.777
U-Net scratch	7.76M	5.6 min	0.766	0.859	0.929	0.756	0.850
U-Net pretrained	14.33M	4.7 min	0.817	0.893	0.946	0.811	0.887

Tabla 2. Comparación de las tres familias. La fila resaltada indica el modelo ganador.




Figura 1. Comparación visual de las 3 familias en Val IoU, Val Dice y Test IoU.

Las curvas de entrenamiento (Figura 2) muestran que **U-Net pretrained empieza desde IoU=0.71 en la primera época**, mientras que las otras dos arrancan en 0.4-0.5. Esto confirma que el encoder preentrenado aporta features visuales útiles desde el primer momento. U-Net scratch supera a SimpleCNN consistentemente, validando el aporte de las skip connections.




Figura 2. Curvas de entrenamiento. Izquierda: pérdida BCE en validación. Derecha: IoU en validación a lo largo de las 15 épocas.

5. Análisis de umbral

Se realizó un barrido del threshold de binarización en el rango [0.3, 0.7] sobre el conjunto de validación del mejor modelo (U-Net pretrained):

Threshold	Val IoU	Val Dice
0.30	0.795	0.879
0.40	0.809	0.888
0.50 (default)	0.817	0.893
0.55 (óptimo)	0.818	0.894
0.60	0.818	0.894
0.70	0.812	0.890

Tabla 3. Threshold sweep sobre validación.

El threshold óptimo es **0.55**, ligeramente superior al default de 0.5, pero la ganancia es marginal (+0.001 IoU). Esto indica que el modelo produce **predicciones bien calibradas** alrededor del valor por defecto, lo cual es señal de un entrenamiento estable.




Figura 3. Threshold sweep sobre validación para U-Net pretrained.

6. Comparación BCE Loss vs Dice Loss

Se reentrenó U-Net from scratch con Dice Loss (que optimiza directamente la métrica de evaluación) para comparar contra BCE Loss bajo el mismo protocolo:

Loss	Val IoU	Val Dice	Test IoU	Test Dice
BCE	0.766	0.859	0.756	0.850
Dice	0.750	0.848	0.746	0.843

Tabla 4. Comparación de losses sobre U-Net from scratch.

Contrariamente a lo que podría esperarse, **BCE Loss superó a Dice Loss** en este experimento (+1.6 puntos en Val IoU). Una posible explicación es que el desbalance moderado del dataset (60/30) no justifica una loss especializada para clases minoritarias, y BCE aprovecha mejor la señal de gradiente píxel a píxel. Se mantiene BCE como loss principal.

7. Análisis de errores por raza

Se calculó el IoU promedio por raza en validación para identificar dónde falla más el modelo. La media global es 0.818, pero hay variabilidad significativa:

Top 5 mejores razas	IoU	Top 5 peores razas	IoU
British Shorthair	0.894	miniature pinscher	0.738
Ragdoll	0.878	shiba inu	0.741
Newfoundland	0.866	american bulldog	0.746
Bombay	0.866	german shorthaired	0.751

Persian	0.860	boxer	0.754
---------	-------	-------	-------

Tabla 5. Razas con mejor y peor desempeño en validación.

Patrón observable: las razas **con peor desempeño son perros de tamaño mediano y pelaje corto** (miniature pinscher, shiba inu, american bulldog, boxer, german shorthaired), donde la silueta puede confundirse con elementos del fondo. Las razas **con mejor desempeño son gatos y perros con siluetas distintivas o pelaje contrastante** (British Shorthair, Ragdoll, Newfoundland, Persian). Este hallazgo sugiere que el modelo depende fuertemente de patrones de textura/contorno.




Figura 4. IoU promedio por raza en validación, ordenado de mejor a peor. La línea punteada marca la media global (0.818).

8. Análisis cualitativo: peores casos

Los 5 peores casos en validación revelan tres modos de error recurrentes (Figura 5):

(1) Ground truth degenerado (caso 1, IoU=0.000): la máscara real está completamente vacía pero la imagen sí muestra un perro. Es un error de anotación del dataset, no del modelo.

(2) Mascota muy pequeña con fondo complejo (caso 2, IoU=0.176): el shiba inu en el bosque ocupa pocos píxeles y el modelo tiene dificultad para distinguirlo del follaje.

(3) Personas en la escena (caso 3, IoU=0.243): el modelo confunde personas con mascotas porque ambas son figuras orgánicas en primer plano. Esta es una **limitación del split binario** usado, que no distingue entre tipos de entidades.




Figura 5. Cinco peores casos en validación con sus IoUs respectivos.

9. ¿Cuál familia parece más prometedora?

Modelo elegido:	U-Net + ResNet18 preentrenado
Threshold óptimo:	0.55
Val IoU:	0.818
Test IoU:	0.811
Parámetros:	14.33M
Tiempo de entren.:	4.7 min (en T4)
Mejora vs E1:	+0.156 IoU absoluto (+24% relativo)

La decisión se sustenta en tres criterios: **(i)** mejor Val IoU (0.818 vs 0.766 vs 0.656); **(ii)** mejor Test IoU (0.811 vs 0.756 vs 0.654), confirmando que la mejora no es sobreajuste a validación; **(iii)** tiempo de entrenamiento competitivo (4.7 min, similar a SimpleCNN). El costo en parámetros (14.33M) es justificable por la ganancia sustancial en desempeño.

El **gap pequeño entre Val IoU y Test IoU (0.007)** indica que el modelo generaliza bien y que el protocolo de validación es honesto. No hay evidencia de data leakage ni sobreajuste.

10. ¿Qué limitaciones siguen abiertas?

- **Resolución limitada a 128×128:** se pierde detalle fino (orejas, patas). Experimentar con 256×256 podría mejorar bordes pero cuadruplica el costo.
- **Augmentación mínima** (solo flip horizontal). Añadir rotaciones, color jitter y crops aleatorios probablemente mejore la robustez.
- **Razas problemáticas** identificadas (perros medianos de pelaje corto). Requeriría augmentación dirigida o muestreo balanceado por raza.
- **Errores de anotación** en el ground truth detectados en el análisis cualitativo. No son culpa del modelo pero impactan las métricas.
- **Hiperparámetros sin tunear** (learning rate, scheduler). Un grid search ligero o un scheduler ReduceLROnPlateau podría mejorar.
- **Una sola semilla:** idealmente se reportaría media $\pm$ std sobre 3+ semillas, pero el costo computacional fue prohibitivo en este tiempo.
- **Personas en la imagen** son confundidas con mascotas: el split binario no ayuda a distinguirlas. Una loss con regularización espacial podría mitigarlo.

11. Plan para Entrega 3

- (1) Tomar el modelo ganador (U-Net + ResNet18) y aplicar las mejoras prioritarias: augmentación más agresiva, scheduler de learning rate y posiblemente resolución 256×256.
- (2) Análisis de **interpretabilidad**: mapas de saliencia o Grad-CAM para entender qué regiones de la imagen activan al modelo.
- (3) Evaluación final consolidada con análisis de sensibilidad y reporte de confianza por predicción.
- (4) **Póster sintético** que comunique los hallazgos principales.